

Техническое задание по анализу временных рядов и RNN

DS

1 Общее описание задания

Цель данного задания — исследовать эффективность различных моделей машинного обучения для прогнозирования временных рядов, включая традиционные алгоритмы и рекуррентные нейронные сети. Особое внимание уделяется созданию и отбору признаков, а также сравнению методов feature selection.

2 Этапы выполнения

2.1 Этап 1: Выбор и анализ временного ряда

2.1.1 Выбор датасета

Выберите временной ряд из предложенных вариантов:

Возможные временные ряды:

1. Энергопотребление

- [Hourly Energy Consumption](#) – почасовое потребление энергии
- [Electricity Load Diagrams 2011-2014](#)
- [Energy Consumption with Weather](#)

2. Погодные данные

- [Weather Dataset](#) – температура, влажность, осадки
- [NOAA Global Hourly Weather](#)
- [OpenWeatherMap API](#) (можно собрать самостоятельно)

3. Транспорт и трафик

- [Traffic Prediction Dataset](#)
- [Metro Interstate Traffic Volume](#)
- [US Accidents Dataset](#) (агрегировать по времени)

4. Здравоохранение и эпидемиология

- [COVID-19 Time Series Data](#)
- [CDC Flu Data](#)
- [COVID-19 Tracking US](#)

5. Экономические показатели

- [FRED Economic Data](#) – ВВП, инфляция, безработица
- [Unemployment and GDP](#)
- [World Bank Open Data](#)

6. Технологические метрики

- [Server Metrics Dataset](#)
- [Website Traffic Time Series](#)
- [Numenta Anomaly Benchmark](#)

7. Социальные и культурные данные

- [Google Trends Data](#)
- [YouTube Trending Videos](#) (агрегировать просмотры)
- [YouTube Statistics](#)

8. Любые финансовые ряды - библиотека уfinance

Минимальные требования к данным:

- Минимум **1000 временных наблюдений**
- Регулярная периодичность (часовая, дневная, недельная, месячная)
- Наличие явных временных паттернов (тренд, сезонность)
- Отсутствие более 10% пропущенных значений

2.1.2 Первичный анализ данных

Проведите исчерпывающий анализ временного ряда:

1. Описательная статистика

- Основные статистики (среднее, медиана, стандартное отклонение, квартили)
- Анализ распределения значений (гистограмма, QQ-plot)
- Выявление выбросов (box plot, z-score анализ)

2. Визуализация временного ряда

- График исходного временного ряда
- Декомпозиция на компоненты (тренд, сезонность, остатки)
- Анализ автокорреляционной функции (ACF)
- Анализ частной автокорреляционной функции (PACF)

3. Статистические тесты

- Тест Дики-Фуллера на стационарность
- Тест Шапиро-Уилка на нормальность остатков
- Тест Льюнга-Бокса на автокорреляцию остатков

2.2 Этап 2: Генерация признаков

Создайте минимум 200 различных временных признаков, разделенных по следующим категориям:

2.2.1 Лаговые признаки (20-30 признаков)

- Простые лаги: $x_{t-1}, x_{t-2}, \dots, x_{t-30}$
- Сезонные лаги: $x_{t-s}, x_{t-2s}, \dots$ где s – период сезонности
- Дифференциальные лаги: $\Delta x_t = x_t - x_{t-1}, \Delta^2 x_t$
- Логарифмические лаги: $\log(x_{t-i})$ для $i = 1, 2, \dots, 10$

2.2.2 Скользящие статистики (40-50 признаков)

Для различных окон ($w \in \{3, 5, 7, 14, 21, 30\}$):

- Скользящее среднее: $MA_w(t) = \frac{1}{w} \sum_{i=0}^{w-1} x_{t-i}$
- Скользящая медиана: $Median_w(t)$
- Скользящее стандартное отклонение: $Std_w(t)$
- Скользящий минимум и максимум: $Min_w(t), Max_w(t)$
- Скользящий размах: $Range_w(t) = Max_w(t) - Min_w(t)$
- Скользящая дисперсия: $Var_w(t)$
- Скользящая асимметрия (skewness): $Skew_w(t)$
- Скользящий эксцесс (kurtosis): $Kurt_w(t)$
- Квантили: $Q_{25,w}(t), Q_{75,w}(t)$
- Межквартильный размах: $IQR_w(t) = Q_{75,w}(t) - Q_{25,w}(t)$

2.2.3 Экспоненциальные скользящие средние (15-20 признаков)

Для различных параметров сглаживания $\alpha \in \{0.1, 0.2, 0.3, 0.5, 0.7, 0.9\}$:

- Простое ЕМА: $EMA_\alpha(t) = \alpha x_t + (1 - \alpha)EMA_\alpha(t - 1)$
- Двойное ЕМА: $DEMA_\alpha(t)$
- Тройное ЕМА: $TEMA_\alpha(t)$
- Адаптивное ЕМА с переменным α

2.2.4 Технические индикаторы (30-40 признаков)

- **Momentum индикаторы:**
 - RSI (Relative Strength Index) с периодами 14, 21, 30
 - Stochastic Oscillator (%K, %D)
 - Williams %R
 - Rate of Change (ROC) с различными периодами
 - Momentum: $M_n(t) = x_t - x_{t-n}$
- **Trend-following индикаторы:**
 - MACD (Moving Average Convergence Divergence)
 - MACD Signal Line
 - MACD Histogram
 - Parabolic SAR
 - Average Directional Index (ADX)
- **Volatility индикаторы:**
 - Bollinger Bands (верхняя, средняя, нижняя полосы)
 - Bollinger Band Width
 - Bollinger Band Position
 - Average True Range (ATR)
 - Volatility Ratio
- **Volume-based индикаторы** (если есть данные о объеме):
 - Volume Weighted Average Price (VWAP)
 - On Balance Volume (OBV)
 - Accumulation/Distribution Line

2.2.5 Временные признаки (20-25 признаков)

- Час дня: $\text{hour}(t)$
- День недели: $\text{dayofweek}(t)$ (one-hot encoding)
- День месяца: $\text{dayofmonth}(t)$
- Месяц года: $\text{month}(t)$ (one-hot encoding)
- Квартал: $\text{quarter}(t)$
- День года: $\text{dayofyear}(t)$
- Неделя года: $\text{weekofyear}(t)$
- Циклические кодировки:
 - $\sin\left(\frac{2\pi \cdot \text{hour}}{24}\right), \cos\left(\frac{2\pi \cdot \text{hour}}{24}\right)$

- $\sin\left(\frac{2\pi \cdot \text{dayofweek}}{7}\right), \cos\left(\frac{2\pi \cdot \text{dayofweek}}{7}\right)$
- $\sin\left(\frac{2\pi \cdot \text{month}}{12}\right), \cos\left(\frac{2\pi \cdot \text{month}}{12}\right)$
- $\sin\left(\frac{2\pi \cdot \text{dayofyear}}{365}\right), \cos\left(\frac{2\pi \cdot \text{dayofyear}}{365}\right)$

- Бинарные признаки: выходной/рабочий день, начало/конец месяца, праздники

2.2.6 Статистические и математические признаки (30-40 признаков)

- **Автокорреляционные признаки:**
 - Автокорреляция с лагами 1, 2, 3, 7, 14, 30
 - Частная автокорреляция с теми же лагами
- **Энтропийные меры:**
 - Приближенная энтропия (ApEn)
 - Выборочная энтропия (SampEn)
 - Перестановочная энтропия
- **Фрактальные характеристики:**
 - Показатель Хёрста
 - Фрактальная размерность
 - Детрендрованный флуктуационный анализ (DFA)
- **Нелинейные меры:**
 - Корреляционная размерность
 - Экспонента Ляпунова
 - Рекуррентная квантификация (RQA)
- **Дополнительные статистики:**
 - Коэффициент вариации
 - Индекс концентрации
 - Количество пересечений нуля
 - Количество локальных экстремумов
 - Энергия сигнала

2.2.7 Частотные признаки (25-30 признаков)

- **Фурье-преобразование:**
 - Коэффициенты дискретного преобразования Фурье (DFT)
 - Спектральная плотность мощности
 - Доминирующие частоты
 - Спектральный центроид
 - Спектральная дисперсия
 - Спектральная асимметрия

- Спектральный эксцесс
- Спектральная энтропия
- **Вейвлет-преобразование:**
 - Коэффициенты вейвлет-преобразования (Daubechies, Morlet)
 - Энергия по масштабам
 - Энтропия вейвлет-коэффициентов
- **Другие частотные методы:**
 - Коэффициенты дискретного косинусного преобразования (DCT)
 - Mel-частотные кепстральные коэффициенты (MFCC)

2.2.8 Комплексные составные признаки (15-20 признаков)

- Отношения различных скользящих средних
- Расстояние от текущего значения до скользящих средних
- Нормализованные позиции в каналах (например, положение в Bollinger Bands)
- Композитные индексы на основе нескольких технических индикаторов
- Признаки пересечения различных индикаторов
- Z-score нормализованные версии основных признаков
- Признаки изменения волатильности
- Признаки детекции паттернов (пики, впадины, тренды)

Итого: 200+ признаков различной природы для комплексного описания временного ряда

2.3 Этап 3: Feature Selection

Реализуйте и сравните два подхода отбора признаков:

2.3.1 Forward Selection

1. Начните с пустого множества признаков
2. Итеративно добавляйте признак, дающий наибольшее улучшение метрики
3. Критерий остановки: улучшение метрики менее 0.5% или достижение максимального количества признаков (50-100)
4. Используйте кросс-валидацию для оценки качества на каждом шаге

Формально:

$$S_0 = \emptyset$$

$$S_{k+1} = S_k \cup \left\{ \arg \max_{f \notin S_k} \text{Score}(S_k \cup \{f\}) \right\}$$

2.3.2 Backward Selection

1. Начните с полного множества признаков
2. Итеративно удаляйте признак, удаление которого минимально ухудшает метрику
3. Критерий остановки: ухудшение метрики более 1% или достижение минимального количества признаков (10-20)
4. Используйте кросс-валидацию для оценки качества на каждом шаге

Формально:

$$S_0 = F \text{ (все признаки)}$$
$$S_{k+1} = S_k \setminus \{\arg \min_{f \in S_k} \text{Score}(S_k \setminus \{f\})\}$$

2.3.3 Дополнительные методы отбора (по желанию)

- Recursive Feature Elimination (RFE)
- LASSO регуляризация для автоматического отбора
- Mutual Information для оценки зависимости
- Permutation Importance
- Variance Threshold для удаления низковариативных признаков

2.4 Этап 4: Обучение и сравнение моделей

Обучите следующие модели на отобранных наборах признаков:

2.4.1 Линейная регрессия (Linear Regression)

- Базовая линейная регрессия с регуляризацией Ridge
- Подберите оптимальный параметр регуляризации α через GridSearchCV
- Диапазон: $\alpha \in [0.01, 0.1, 1, 10, 100, 1000]$

2.4.2 Gradient Boosting Regressor

- Используйте XGBoost или LightGBM
- Настройте гиперпараметры:
 - $n_estimators \in [100, 300, 500, 1000]$
 - $max_depth \in [3, 5, 7, 10]$
 - $learning_rate \in [0.01, 0.05, 0.1, 0.2]$
 - $subsample \in [0.8, 0.9, 1.0]$
- Используйте early stopping для предотвращения переобучения

2.4.3 LSTM (Long Short-Term Memory)

- Архитектура:
 - 1-2 LSTM слоя с 50-128 нейронами каждый
 - Dropout 0.2-0.3 между слоями
 - Dense выходной слой
- Гиперпараметры:
 - Размер окна (sequence length): $\in [10, 20, 30, 50]$
 - Batch size: $\in [16, 32, 64]$
 - Learning rate: $\in [0.001, 0.01, 0.1]$
 - Количество эпох с early stopping
- Используйте признаки как дополнительные входы или исключительно последовательности лагов

2.5 Этап 5: Валидация и метрики

2.5.1 Схема валидации

Используйте **Time Series Split** для корректной валидации:

- Разделите данные на train/validation/test в пропорции 70%/15%/15%
- Для кросс-валидации используйте TimeSeriesSplit с 5 фолдами
- Обеспечьте отсутствие утечки данных из будущего в прошлое

2.5.2 Метрики качества

Рассчитайте следующие метрики для всех моделей:

1. Mean Absolute Error (MAE):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

2. Root Mean Square Error (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

3. Mean Absolute Percentage Error (MAPE):

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

4. Symmetric Mean Absolute Percentage Error (SMAPE):

$$\text{SMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

5. R-squared (R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

3 Анализ и визуализация результатов

3.1 Обязательные графики и таблицы

1. Исходные данные:

- График временного ряда
- Декомпозиция (тренд, сезонность, остатки)
- ACF и PACF графики
- Гистограмма распределения значений

2. Feature Selection:

- График изменения метрики качества по итерациям для Forward Selection
- График изменения метрики качества по итерациям для Backward Selection
- Сравнительная таблица финальных наборов признаков
- Важность признаков (feature importance) для gradient boosting модели

3. Сравнение моделей:

- Сводная таблица всех метрик по всем моделям
- График предсказаний vs фактических значений для лучшей модели
- Графики остатков (residuals) для анализа качества
- Learning curves для LSTM модели

4. Анализ ошибок:

- Временные графики ошибок предсказания
- Анализ распределения остатков
- Выявление периодов с наибольшими ошибками

3.2 Исследовательские вопросы

Проанализируйте и ответьте на следующие вопросы:

1. Сравнение методов Feature Selection:

- Какой метод (Forward/Backward) дает лучший результат?
- Сколько признаков оптимально для каждого метода?
- Какие категории признаков чаще всего отбираются?
- Есть ли пересечения в итоговых наборах признаков?

2. Сравнение моделей:

- Какая модель показывает лучшие результаты?
- Как качество зависит от количества используемых признаков?
- Переобучается ли LSTM модель и как это предотвратить?
- Какие признаки наиболее важны для каждой модели?

3. Анализ временных паттернов:

- В какие периоды модели дают наибольшие ошибки?
- Связаны ли ошибки с особенностями временного ряда (выбросы, смена тренда)?
- Как модели справляются с сезонностью?

4 Требования к отчету

4.1 Структура отчета

1. Введение

- Описание выбранного датасета
- Постановка задачи прогнозирования
- Гипотезы исследования

2. Анализ данных

- Описательная статистика
- Визуализация временного ряда
- Результаты статистических тестов
- Выводы о характеристиках ряда

3. Генерация признаков

- Подробное описание всех категорий признаков
- Обоснование выбора методов генерации
- Статистика по созданным признакам (количество, корреляции)

4. Feature Selection

- Описание алгоритмов Forward и Backward Selection
- Результаты применения каждого метода
- Сравнительный анализ отобранных признаков

5. Моделирование

- Описание архитектур и гиперпараметров моделей
- Процесс обучения и валидации
- Настройка гиперпараметров

6. Результаты

- Сводная таблица всех метрик
- Сравнительный анализ моделей
- Статистическая значимость различий

7. Анализ и выводы

- Ответы на исследовательские вопросы
- Интерпретация результатов
- Ограничения исследования
- Рекомендации по практическому применению

8. Заключение

- Краткое резюме главных выводов
- Направления дальнейших исследований

4.2 Технические требования

- **Код:** чистый, комментированный Python код в Jupyter Notebook
- **Воспроизводимость:** фиксация random seed, подробные инструкции
- **Графики:** высококачественные визуализации с подписями осей и легендами
- **Таблицы:** аккуратно оформленные таблицы с округлением до 3-4 знаков
- **Объем:** отчет 15-25 страниц (без учета кода и приложений)